

tempssm 詳細マニュアル

Version 0.2.3.1

平尾章・馬場真哉・市野川桃子

2026-06-24

概要

`tempssm` は、気温・水温などの温度時系列に対する状態空間解析を行うための R パッケージです。計算バックエンドとして、KFAS R パッケージ (Helske, 2017) を用い、カルマンフィルタリングおよび平滑化によって推定される線形ガウス状態空間モデルを適用します。

主な特徴

- 温度時系列に線形ガウス状態空間モデルを適用
- 温度の動態を潜在状態 (latent state) の次の各成分に分解して表現：長期トレンド、季節変動、自己回帰構造、および任意の外生効果
- 任意の季節周期に対応（ただし実例と検証では、主として月別の温度データを対象）
- 自己回帰成分の次数の任意指定が可能
- 要約、モデル診断、プロットのための S3 メソッドを提供
- モデル評価のための時系列交差検証ツールを提供

既存研究と本パッケージの範囲

`tempssm` は、線形ガウス状態空間モデルを用いて温度時系列を解析するための、対象分野に特化したワークフローを提供します。温度データへの応用に合わせた単一の R パッケージインターフェースの中に、モデル構築、成分抽出、不確実性の要約、残差診断、可視化、時系列交差検証を統合しています。

本パッケージは、線形ガウス状態空間モデリング、カルマンフィルタリング、カルマン平滑化を含む、確立された統計的方法論に基づいています。モデル推定は、R における状態空間モデルの汎用的な枠組みを提供する KFAS パッケージを通じて行われます。

初期実装は、線形ガウス状態空間モデルを用いて海水温トレンドを解析した Baba et al. (2024) に付随する補足コードに基づいています。この補足コードは以下で公開されています。

<https://github.com/logics-of-blue/sea-temperature-trend-jogashima>

この先行実装と比べて、`tempssm` は、入力検証、文書化された S3 メソッド、テスト、診断、交差検証ユーティリティ、およびより広範な温度時系列解析のための例を備えた、再利用可能な R パッケージインターフェースへとワークフローを拡張しています。

次節では、`tempssm` で用いる状態空間モデルを説明し、長期トレンド、季節成分、自己回帰成分、外生成分がどのように表現されるかを整理します。

tempssm における状態空間モデル

本パッケージでは、長期トレンド、季節変動、自己回帰成分を明示的に含む温度時系列を記述するために、基本構造時系列モデル (Basic Structural Time Series Model; BSTSM) を拡張したモデルを考えます。観測方程式は次のように表されます。

$$y_t = \alpha_t + v_t. \quad (1)$$

ここで、 t は時点、 y_t は観測された温度、 α_t は潜在状態、 v_t は観測誤差を表します。

潜在状態は次のように分解されます。

$$\alpha_t = \mu_t + s_t + r_t + E_t. \quad (2)$$

ここで、 μ_t は長期トレンド成分、 s_t は季節成分、 r_t は定常的な自己回帰成分、 E_t は外生変数の寄与を表します。

レベル成分は、次の 2 次の確率過程に従います。

$$\mu_t = 2\mu_{t-1} - \mu_{t-2} + \zeta_t, \quad \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2). \quad (3)$$

ここで、 ζ_t は長期トレンド成分の過程誤差です。

季節成分は、総和ゼロ制約をもつモデルとして表されます。

$$s_t = - \sum_{i=t-f}^{t-1} s_i + \omega_t, \quad \omega_t \sim \mathcal{N}(0, \sigma_\omega^2). \quad (4)$$

ここで、 ω_t は季節成分の過程誤差、 f は季節周期を表します (例えば 月別データでは $f = 12$)。この定式化により、季節効果は識別可能となり、異なる時間分解能の間でも比較しやすくなります。1つの完全な季節周期にわたって総和ゼロ制約を課すことで、季節成分は長期的なドリフトを導入することなく、基礎となる長期トレンドからの反復的な偏差を捉えます。季節成分を含まないモデルでは、季節項 s_t はゼロとし、状態方程式から省略されます。

自己回帰成分は、 l 次の自己回帰 (AR) 過程に従います。

$$r_t = \phi_1 r_{t-1} + \phi_2 r_{t-2} + \dots + \phi_l r_{t-l} + \tau_t, \quad \tau_t \sim \mathcal{N}(0, \sigma_\tau^2). \quad (5)$$

ここで、 τ_t は自己回帰成分の過程誤差を表します。過程誤差項 (ζ_t 、 ω_t 、および τ_t) は互いに独立で、正規分布に従うと仮定します。

外生成分は次のように定義されます。

$$E_t = \beta_1 x_{1,t} + \beta_2 x_{2,t} + \dots + \beta_m x_{m,t}. \quad (6)$$

外生項 E_t は外部要因の影響を表します。外部要因には、大規模な気候指数、地域的な環境変数、あるいは観測された温度時系列に関連する物理的根拠をもつ予測変数などが含まれます。各外生変数は、時間に依存しない回帰係数 ($\beta_1, \beta_2, \dots, \beta_m$) を通じて線形にモデルへ組み込まれ、その寄与の大きさと方向を潜在状態成分と同時に推定できます。

観測データにモデルを適用する際、推定されるパラメータの総数 (k) は、自己回帰成分の次数と、モデルに含まれる外生変数の数に依存します。例えば、2 次の自己回帰成分をもち、外生共変量を含まないモデルでは、観測誤差分散、長期トレンド・季節・自己回帰成分に対応する過程誤差分散、および 1 次・2 次の自己回帰係数 (ϕ_1 と ϕ_2) の計 6 個のパラメータが推定されます。一般に、 l 次の自己回帰成分と m 個の外生変数をもつ場合、パラメータの総数は $k = 4 + l + m$ です。

パラメータ推定手順の中核的な実装は、Baba et al. (2024) によって提供された補足コードに基づいています。パラメータ推定は、Helske (2017) が推奨する 2 段階の最適化戦略によって行われます。第 1 段階では、ユーザー指定の初期値を用いて Nelder-Mead 法 (Nelder & Mead, 1965) によりモデルパラメータを推定します。得られた推定値を、第 2 段階の BFGS アルゴリズム (Shanno, 1970) による最適化の初期値として用います。本パッケージの主要関数である `tempssm()` は、モデルの構築からパラメータ推定までを一挙に実施し、フィルタリング推定値と平滑化推定値の両方を `tempssm` オブジェクトに返り値とし格納します。一方で、S3 メソッドを介して示される要約、モデル診断、プロットで示す結果はすべて平滑化推定値に基づいています。

使用方法

環境設定

以下の例を実行するため、以下の R パッケージを読み込みます。未インストールのパッケージがあれば、適宜、インストールください。

```
## Set libraries
library(tempssm)
library(forecast)

library(purrr)
library(tibble)
library(readr)
library(dplyr)
library(ggplot2)

library(patchwork)
```

入力データ形式

`tempssm` への入力データは、等間隔の時系列を表す R の `ts` オブジェクトとして与える必要があります (`?stats::ts` または <https://stat.ethz.ch/R-manual/R-devel/library/stats/html/ts.html> を参照してください)。

データ準備を支援するため、本パッケージには、外部の観測データを `ts` オブジェクトへ変換するユーティリティ関数が含まれています (付録を参照)。

演習 I: 単変量の温度時系列への状態空間モデルの適用

目的

演習 I では、単変量の温度時系列に線形ガウス状態空間モデルを適用する方法を実践します。外生変数を含めない基本的なモデリングの導入に位置づけられます。あわせて自己回帰的な動態が果たす役割を検討します。

海面水温 (SST) データセットの読み込み

本パッケージには、以下の海面水温 (SST) のサンプルデータセットが含まれています。

- データセット: 山口県沖の月別海面水温 (SST)
- 単位: °C
- 期間: 2002 年 2 月から 2023 年 12 月

このデータセットは、気象庁ウェブサイト (<https://www.jma.go.jp/jma/indexe.html>) から取得した日別 SST データセットを月別に集約したものです。

```
data(yamaguchi_sst) # load a ts object of SST off Niigata
head(yamaguchi_sst)
```

```
##           Jan           Feb           Mar           Apr           May           Jun
## 1982 14.85516 13.36500 13.55645 14.29933 17.72419 21.53000
```

```
summary(yamaguchi_sst)
```

```
##           Temp
## Min.       :11.45
## 1st Qu.:15.13
```


```
## Median :18.84
## Mean   :19.54
## 3rd Qu.:23.63
## Max.   :29.49
```

月別 SST 時系列のプロット

まず、月別 SST 時系列を可視化し、見かけのトレンド、季節変動、欠測値の有無を含む全体的な構造を確認しておきます。

```
plt_yamaguchi_sst <- forecast::autoplot(yamaguchi_sst) +
  labs(y = expression(Temp.~(degree*C)),
       x = "Time (year)") +
  ggtitle("Monthly SST off Yamaguchi, Japan") +
  theme_classic()

plot(plt_yamaguchi_sst)
```



線形ガウス状態空間モデルの適用

本パッケージのコア関数 `tempssm()` に温度時系列データの `ts` オブジェクト（ここでは `yamaguchi_sst`）を与えて、実行すると、モデル構築からパラメータ推定までが一挙に処理されます。返り値として、フィルタリング推定値、平滑化推定値などの結果に加えて、構築されたモデルや入力データなどが S3 クラスの `tempssm` オブジェクト（ここでは `res_ar1`）に格納されます。デフォルトでは `tempssm()` は 1 次の自己相関回帰モデルをあてはめます。

```
# model with first-order autoregressive component
res_ar1 <- tempssm(yamaguchi_sst) # (ar_order=1: default)
```

```
summary(res_ar1)
```

```
## tempssm summary
## -----
## Call:
## tempssm(temp_data = yamaguchi_sst)
##
## Model fit:
##   Log-likelihood : -470.61
##   k               : 5
##   AIC             : 951.21
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 4.542027e-14
##   State (Q trend): 9.936473e-08
##   State (Q season): 8.408352e-56
##   State (Q ar): 0.3145626
##
## Components of auto-regression:
##   Order of AR: 1
##   Coefficient of AR1: 0.6202321
```

結果の要約から、モデルが収束したこと (Converged: TRUE) を確かめます。その他に統計量として、パラメータ数 (k)、対数尤度 (Log-likelihood)、赤池情報量基準 (AIC) が示されています。パラメータ推定値の内訳は次のとおりです：観測誤差の分散 (H)、長期トレンド成分の過程誤差の分散 (Q trend)、季節周期成分の過程誤差の分散 (Q season)、自己回帰成分の過程誤差の分散 (Q trend)、1 次の自己回帰係数 (AR1)

自己回帰 (AR) 次数の検討

次に、自己回帰 (AR) 次数がモデルの挙動に与える影響を調べます。具体的には、明示的な季節周期を含むその他のモデル成分を同一に保ったまま、自己回帰成分の次数を 1 から 3 まで変化させた 3 つのモデルを当てはめます。1 次のモデルは取得済みなので、2 次と 3 次のモデルを実行します。

```
# model with second-order autoregressive component
res_ar2 <- tempssm(yamaguchi_sst, ar_order=2)
summary(res_ar2)
```

```
## tempssm summary
## -----
## Call:
## tempssm(temp_data = yamaguchi_sst, ar_order = 2)
##
## Model fit:
##   Log-likelihood : -467.66
##   k               : 6
##   AIC             : 947.33
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 0.120908
##   State (Q trend): 2.206262e-07
##   State (Q season): 5.525557e-16
##   State (Q ar): 0.1044204
##
```

```
## Components of auto-regression:
##   Order of AR: 2
##   Coefficient of AR1: 1.185818
##   Coefficient of AR2: -0.4790522

# model with third-order autoregressive component
res_ar3 <- tempssm(yamaguchi_sst, ar_order=3)
summary(res_ar3)

## tempssm summary
## -----
## Call:
## tempssm(temp_data = yamaguchi_sst, ar_order = 3)
##
## Model fit:
##   Log-likelihood : -467.5
##   k               : 7
##   AIC             : 949
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 0.1123192
##   State (Q trend): 2.242518e-07
##   State (Q season): 9.553973e-10
##   State (Q ar): 0.1245964
##
## Components of auto-regression:
##   Order of AR: 3
##   Coefficient of AR1: 1.07459
##   Coefficient of AR2: -0.3334548
##   Coefficient of AR3: -0.06336897
```

異なる AR 次数のモデルを比較することで、短期的およびより長期的な時間依存性が状態空間の枠組みの中でどのように表現されるかを評価します。ここでは簡便的に AIC に基づいたモデル比較と選択をおこないます。

AIC に基づくモデル選択

```
# Extract AIC
AIC(res_ar1)

## [1] 951.2127

AIC(res_ar2)

## [1] 947.3283

AIC(res_ar3)

## [1] 949.0037

AIC_table_res <- tibble(model=c("AR1", "AR2", "AR3"),
                        AIC = c(AIC(res_ar1), AIC(res_ar2), AIC(res_ar3))) %>%
  mutate(delta_AIC = AIC - min(AIC))


AIC_table_res %>% knitr::kable()
```

model	AIC	delta_AIC
AR1	951.2127	3.884414
AR2	947.3283	0.000000
AR3	949.0037	1.675466

AR2 モデルは、他のモデルよりも AIC が小さく良好であることが確認できます。以下の検討は、AR2 モデルを用いて進めていきます。

長期トレンド、ドリフト、季節成分、自己回帰成分のプロット 状態空間モデルから対応する潜在成分を抽出し、推定された温度レベルの長期的な変化と、その変化率（ドリフト）を可視化します。あわせて季節変動と自己回帰的依存性もプロットすることで、基礎となるトレンド構造をより明確に確認できます。

```
# plot all components at once
plot(res_ar2)
```



パネル左上の長期トレンドは、解析期間を通じて SST 上昇していくパターンを示しています。このグラフの例において、解析期間を通じた SST の平均的な年上昇率は約 0.036 °C です。

しかしながら、SST の変化率そのものも時系列に沿って変化しているようです。パネル右上の変化率（ドリフト）に注目すると、2000 年代に 変化率が 0（または 0 の近傍）に低下した後、2010 年以降に上昇したことが読み取れます。灰色の網掛け部分は、推定された潜在状態 の 95% 信頼区間を表し、各推定成分に伴う不確実性を示しています。

標準的なプロット用インターフェースは `plot(res)` です。ggplot2 形式の インターフェースである `autoplot(res)` も利用でき、デフォルトでは同じ成分プロットを生成します。個別の成分について ggplot オブジェクトを取得するには、以下のように `autoplot()` の `component` 引数を指定します。


```
# plot each of components at once
plt_level <- autoplot(res_ar2, component = c("level"))
plt_drift <- autoplot(res_ar2, component = c("drift"))
plt_season <- autoplot(res_ar2, component = c("season"))
plt_ar1 <- autoplot(res_ar2, component = c("ar1"))
```

モデル診断

```
diag <- diagnose_residuals(res_ar2)
print(diag)
```

```
## # A tibble: 1 x 4
##   lb_stat lb_df lb_pvalue kurtosis
##   <dbl> <dbl>   <dbl>   <dbl>
## 1     3.68     2     0.158     3.66
```

```
plot_tempsm_residual_diagnostics(res_ar2)
```



モデル診断プロットにおいて、上パネルは残差の時系列プロット、下左パネルは残差の自己相関プロット（ACFプロット）、下右パネルは残差の頻度分布プロットを表します。残差の各パターンについて留意すべき点がないかをチェックしておきます。Ljung-Box 検定では、残差の自己相関に有意性は認められませんでした ($P = 0.996$)。

推定されたパラメータと潜在状態の成分

長期トレンド成分やその変化率（ドリフト）は、次のように `ts` オブジェクトとして 取り出すことができます。

```
# Smoothing estimates
alpha_hat <- res_ar2$kfs$alphahat
```

```
head(alpha_hat)
```

```
##           level      slope sea_dummy1 sea_dummy2 sea_dummy3 sea_dummy4
## Jan 1982 18.95931 0.002015924 -4.388281 -1.989806 0.8433008 3.3260567
## Feb 1982 18.96132 0.002016062 -5.783414 -4.388281 -1.9898060 0.8433008
## Mar 1982 18.96334 0.002016254 -5.905548 -5.783414 -4.3882811 -1.9898060
## Apr 1982 18.96536 0.002016894 -4.594205 -5.905548 -5.7834141 -4.3882811
## May 1982 18.96737 0.002017326 -1.902724 -4.594205 -5.9055484 -5.7834141
## Jun 1982 18.96939 0.002017769 1.458513 -1.902724 -4.5942046 -5.9055484
##           sea_dummy5 sea_dummy6 sea_dummy7 sea_dummy8 sea_dummy9 sea_dummy10
## Jan 1982 6.1502216 7.6638746 5.1220111 1.4585130 -1.902724 -4.594205
## Feb 1982 3.3260567 6.1502216 7.6638746 5.1220111 1.458513 -1.902724
## Mar 1982 0.8433008 3.3260567 6.1502216 7.6638746 5.122011 1.458513
## Apr 1982 -1.9898060 0.8433008 3.3260567 6.1502216 7.663875 5.122011
## May 1982 -4.3882811 -1.9898060 0.8433008 3.3260567 6.150222 7.663875
## Jun 1982 -5.7834141 -4.3882811 -1.9898060 0.8433008 3.326057 6.150222
##           sea_dummy11 arima1 arima2
## Jan 1982 -5.905548 0.2080998 -0.06449083
## Feb 1982 -4.594205 0.2341012 -0.09969067
## Mar 1982 -1.902724 0.2821581 -0.11214667
## Apr 1982 1.458513 0.2875601 -0.13516843
## May 1982 5.122011 0.5397162 -0.13775631
## Jun 1982 7.663875 0.5449238 -0.25855222
```

```
# Smoothing estimate of level component
level_ts <- get_level_ts(res_ar2)

# Smoothing estimate of drift component
drift_ts <- get_drift_ts(res_ar2)

# Average drift rate per year across the full period
mean_drift_year <- mean(drift_ts)
print(mean_drift_year)
```

```
## [1] 0.03663453
```

SST の平均的な年上昇率は 0.0366 °C と推定されました。

演習 II: 外生変数を伴う温度時系列への状態空間モデルの適用

目的

状態空間モデリングのフレームを拡張して、外生的要因が温度変動に与える影響を検討します。具体的には、外生変数としての太平洋十年規模振動 (Pacific Decadal Oscillation; PDO) が、山口県沖で観測された SST に与える影響を検討します。

PDO 指数データセットの読み込み: 外生変数としての PDO 指数

- データ: 月別の太平洋十年規模振動 (PDO) 指数 (JMA)
- 期間: 1901 年 1 月から 2025 年 12 月

太平洋十年規模振動 (PDO) 指数は、20°N 以北の北太平洋における SST 変動の第 1 経験直交関数 (EOF) に、月平均 SST 偏差を射影したものとして定義されます。EOF は、1901 年から 2000 年の月別平年値を基準として定義された、1901–2000 年の SST 偏差を用いて計算されます。地球温暖化シグナルを取り除くため、EOF 解析に先立ち、各格子点から全球平均 SST 偏差が差し引かれます。本パッケージでは、気象庁 (JMA) が提供

する PDO 指数を使用します。データは https://www.data.jma.go.jp/kaiyou/data/shindan/b_1/pdo/pdo.txt で入手できます。

```
data(pdo) # load a ts object of NAO index
head(pdo)
```

```
##           Jan      Feb      Mar      Apr      May      Jun
## 1901  1.0040  0.7403  0.9011 -0.0109 -0.2325 -0.6810
```

温度時系列と PDO 時系列の共通期間への切り出し

外生変数を伴う状態空間モデリングでは、すべての入力時系列が共通かつ整合した時間インデックスをもつ必要があります。このステップでは、温度時系列と PDO 時系列について、先頭および末尾の重ならない部分を切り落とし、両データセットが同一の期間の範囲となるようにします。

`tempssm::trim_ts_overlap()` 関数を用いて 2 つの `ts` オブジェクトを共通の時間軸にそろえ、共通期間のみを含む多変量時系列を返します。

```
# Generate an object on a shared timeline
yamaguchi_sst_trim <- trim_ts_overlap(yamaguchi_sst,
                                     pdo,
                                     temp_name = "Temp",
                                     exo_name="PDO")$temperature
```

```
pdo_trim <- trim_ts_overlap(yamaguchi_sst,
                           pdo,
                           temp_name = "Temp",
                           exo_name="PDO")$exogenous
```

```
start(yamaguchi_sst_trim)
```

```
## [1] 1982    1
```

```
end(yamaguchi_sst_trim)
```

```
## [1] 2025   12
```

```
start(pdo_trim)
```

```
## [1] 1982    1
```

```
end(pdo_trim)
```

```
## [1] 2025   12
```

海面水温と PDO 指数の時系列プロット


海面水温と PDO 指数の時系列構造を可視化して把握します。

```
plt_yamaguchi_sst_trim <- forecast::autoplot(yamaguchi_sst_trim) +
  labs(y = expression(Temp.~(degree*C)),
       x = "Time (year)") +
  ggtitle("Monthly SST off Yamaguchi, Japan") +
  theme_classic()
```

```
plt_pdo <- forecast::autoplot(pdo_trim) +
  labs(x = "Time (year)", y = "PDO index") +
```

```
ggtitle("PDO index") +
theme_classic()

plt_yamaguchi_sst_trim + plt_pdo + patchwork::plot_layout(ncol=1)
```



外生変数を含まないモデルの適用

まず、外生変数を含まないベースラインの状態空間モデルを適用します。このモデルは、温度変動が潜在的な長期トレンド、季節周期、自己回帰的依存性のみで説明される参照ケースとして機能します。既に演習 I で同一のモデルを取得していますが、ここでは従属変数の引数を明示して実行し、返り値を `res_without` とします。

```
res_without <- tempssm(temp_data = yamaguchi_sst_trim, ar=2)
summary(res_without)
```

```
## tempssm summary
## -----
## Call:
## tempssm(temp_data = yamaguchi_sst_trim, ar_order = 2)
##
## Model fit:
##   Log-likelihood : -466.08
##   k               : 6
##   AIC             : 944.17
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 0.1207584
##   State (Q trend): 2.163319e-07
```

```
## State (Q season): 2.411001e-20
## State (Q ar): 0.1071204
##
## Components of auto-regression:
## Order of AR: 2
## Coefficient of AR1: 1.17824
## Coefficient of AR2: -0.4720514
```

結果の要約は、演習 I でおこなった `summary(res_ar2)` と同じものとなるはずです。事前に AR(1) から AR(3) までの自己回帰次数を検討した結果、ベースラインモデルのみならず、外生 PDO 指数を含むモデルのいずれにおいても、AR(2) が最良のモデル適合を示しました。本マニュアルでは割愛しますが、関心のあるユーザーは、自身の解析において別の AR 次数も検討してください。

このベースラインモデルは、次節で導入する PDO 指数の追加的な説明力を評価するための有用な基準となります。

外生変数を含むモデルの適用

PDO 指数を単変量の外生変数とするモデルを構築します。`tempssm()` 関数において、外生変数用の引数 (`exo_data`) に PDO 指数のデータ (`pdo_trim`) を与えます。これまで明示していませんでしたが、温度時系列データ (`yamaguchi_sst_trim`) は 従属変数の引数 (`temp_data`) に 与えます。

```
res_with <- tempssm(temp_data = yamaguchi_sst_trim,
                    exo_data = pdo_trim,
                    ar_order = 2)

summary(res_with)

## tempssm summary
## -----
## Call:
## tempssm(temp_data = yamaguchi_sst_trim, exo_data = pdo_trim,
##       ar_order = 2)
##
## Model fit:
##   Log-likelihood : -427.33
##   k               : 7
##   AIC             : 868.65
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 0.05749006
##   State (Q trend): 3.832674e-19
##   State (Q season): 1.5571e-54
##   State (Q ar): 0.1792551
##
## Components of auto-regression:
##   Order of AR: 2
##   Coefficient of AR1: 0.8656257
##   Coefficient of AR2: -0.1615369
## Exogenous variable   PDO
## Estimated coefficient -0.4406609
## Lower CI -0.5296035
## Upper CI -0.3517183
```

モデルの推定結果を確認します。外生 PDO 指数の推定係数は負 (-0.44) であり、その 95% 信頼区間はゼロ

を含みません

-0.53, -0.35

。これは、山口県沖の局所的な SST と PDO の変動との間に、統計的に有意な関係があることを示しています。

具体的な解釈として、基礎となる長期トレンド、季節周期、自己回帰の依存性を考慮した後でも、PDO 指数が 1 単位増加すると、月別 SST は平均して約 0.44 °C 低下することがモデルから示唆されます。この結果は、PDO の正の位相が、調査地点における低温の条件に体系的に寄与することを意味します。

重要な点として、この外生変数の効果は、長期トレンドや時間依存性の表現が改善されたことによる見かけの効果としてではなく、温度時系列の内部動態に加えられた、もう一つ要因として識別されています。外生変数を含まないベースラインモデルと比べて PDO 係数が統計的に有意であることは、PDO が局所的な温度変動に影響する独立した大規模気候駆動因子として作用していることを示します。

次に、赤池情報量規準（AIC）を用いて、2 つのモデルの全体的な適合度を比較します。

AIC に基づくモデル比較

AIC のようなモデル選択規準は、適合度とモデル複雑性のバランスを考慮した、モデルの妥当性に関する定量的な指標を提供します。AIC が低いほど、より儉約的で、データからの支持が強いモデルであることを示します。

```
AIC_without <- AIC(res_without)
AIC_with <- AIC(res_with)

models_AICs <- tibble(
  model = c("Without", "With"),
  AIC = c(AIC_without, AIC_with),
  delta_AIC = min(AIC) - AIC
)

models_AICs %>% knitr::kable()
```

model	AIC	delta_AIC
Without	944.1678	-75.51744
With	868.6503	0.00000

PDO 指数を外生変数として含むモデルは、外生変数を含まないベースラインモデルよりも大幅に低い AIC を示し、全体的な適合が明らかに改善していることを示しています。この結果は、PDO の変動を明示的に考慮することで、内部動態のみで説明する場合よりも、温度時系列の統計的記述が改善されるという結論を支持します。

AIC に基づく比較が意味をもつのは、同じ期間の同じ時系列に当てはめられたモデル同士に限られる点に注意が必要です。さらに、状態空間モデルにおける AIC の差は、回帰効果と潜在成分の確率構造の変化の両方を反映します。したがって、AIC は推論の唯一の根拠とするのではなく、パラメータ推定値とその不確実性と併せて用いる補助的な診断指標として扱うべきです。

モデルの頑健性と予測性能をさらに評価するため、さらに以下で述べる時系列交差検証を用います。

時系列交差検証（tsCV）

時系列交差検証（tsCV）は、データの時間的な順序を保ちながら、標本外予測誤差に基づいてモデル性能を評価する方法です。そのため、モデルの妥当性について、追加的かつ独立した観点を提供します。

時系列交差検証では、拡張もしくはスライドする訓練期間に対してモデルを繰り返し当てはめ、その後続の観測値に対する予測性能を評価します。ランダムな交差検証とは異なり、未来から過去への情報漏洩が防がれるため、時系列データのモデル検証に適しています。

ここでは外生 PDO 変数を含むモデルと含まないモデルの交差検証指標を比較することで、AIC が示唆する改善が標本外予測性能にも反映されているかを評価します。

```
# (Optional) Load packages for parallel processing.
# These are only required if you want to enable parallel execution:
# - future: controls how parallel workers are launched
# - future.apply: provides parallelized apply functions
# - progressr: optional progress bar support
library(future.apply)
library(future)
library(progressr)

if (interactive()) {
  future::plan(multisession)
} else {
  future::plan(sequential)
}

# ts cross-validation of the model without exogenous variables

## Generate a list of training and test datasets with their indices
# Procedure for constructing year-based time-series cross-validation folds:
#
# First training data: January 1982–December 2017;
# First test data: one year starting from January 2018
#
# Second training data: January 1983–December 2018;
# Second test data: one year starting from January 2019
# ...
#
# Eighth training data: January 1989–December 2024;
# Eighth test data: one year starting from January 2025
#
# These folds are automatically generated by the ts_train_test_split() function.

# Generate training and test dataset for model without PDO index
folds_without <- ts_train_test_split(
  temp_data = yamaguchi_sst_trim,
  exo_data = NULL,
  initial = 432, # 432 monthly observations from Jan 1982 to Dec 2017
  horizon = 12, # forecast 12 monthly time-series
  step = 12, # training data is moved by 12 months (1 years) steps
  fixed_window = TRUE,
  allow_partial = FALSE
)

# Generate training and test dataset for model with PDO index
folds_with <- ts_train_test_split(
  temp_data = yamaguchi_sst_trim,
  exo_data = pdo_trim,
  initial = 432, # 432 monthly observations from Jan 1982 to Dec 2017
  horizon = 12, # forecast 12 monthly time-series
  step = 12, # training data is moved by 12 months (10 years) steps
```

```

fixed_window = TRUE,
allow_partial = FALSE
)

# *****
# Executing time-series cross validation

#-----
# Model without the exogenous variable of PDA index

# Single processing
# cv_without_results <- ts_cv_run(folds_without, ar_order = 2, use_season = TRUE)

# Parallel processing
cv_without_results <- future.apply::future_lapply(
  folds_without,
  ts_cv_run_fold,
  ar_order = 2,
  use_season = TRUE,
  future.seed = TRUE
)

# Computing assessment indexes
metrics_without <- lapply(cv_without_results, compute_cv_metrics)

# tidy summary
cv_without_tbl <- ts_cv_collect(cv_without_results, metrics_without) %>%
  mutate(Model="Without")

#-----
# Model with the exogenous variable of PDA index

# Single processing
# cv_with_results <- ts_cv_run(folds_with, ar_order = 2, use_season = TRUE)

# Parallel processing
cv_with_results <- future.apply::future_lapply(
  folds_with,
  ts_cv_run_fold,
  ar_order = 2,
  use_season = TRUE,
  future.seed = TRUE
)

# Computing assessment indexes
metrics_with <- lapply(cv_with_results, compute_cv_metrics)

# tidy summary
cv_with_tbl <- ts_cv_collect(cv_with_results, metrics_with) %>%
  mutate(Model="With")

```

```

cv_tbl <- bind_rows(cv_without_tbl, cv_with_tbl)


plt_MAE <- ggplot(data=cv_tbl,
                  aes(x=Model,y=MAE)) +
  geom_boxplot()

plt_MASE_naive <- ggplot(data=cv_tbl,
                        aes(x=Model,y=MASE_naive)) +
  geom_boxplot()

plt_MASE_seasonal <- ggplot(data=cv_tbl,
                           aes(x=Model,y=MASE_seasonal)) +
  geom_boxplot()

plt_tsCV <- plt_MAE + plt_MASE_naive + plt_MASE_seasonal + patchwork::plot_layout(nrow=1)
plot(plt_tsCV)

```



tsCV の解析結果は、外生変数を含むモデルが、外生変数を含まないモデルよりも良好であることを示しています。このチュートリアルでは、実行時間を短縮するため、tsCV の反復回数を 8 回に設定しています。実際の検証では、十分な回数の反復を行ってください。

以上の結果を総合すると、状態空間モデルに外生変数として PDO 指数を含めることが一貫して支持されます。PDO 係数は統計的に有意であり、温度変動に対する明確な効果を示しています。また、AIC の改善は全体的なモデル適合の向上を示しています。さらに、時系列交差検証により、この改善が標本外予測性能の向上にもつながっていることが確認されます。

これらの相補的な証拠は、外生変数を含むモデルを採用するための頑健で多面的な根拠を提供します。

外生変数あり/なしモデルの推定パターンの比較



長期トレンドとその変化率の推定パターンが、外生変数あり/なしモデルでどのように変わったかを見比べてみます。

```
plt_level_without_ts <- autoplot(res_without,
                                component=c("level")
                                ) +
  labs(title="Model without the PDO index") +
  theme_classic()

plt_drift_without_ts <- autoplot(res_without,
                                component=c("drift")
                                ) +
  labs(title="Model without the PDO index") +
  theme_classic()

plt_level_drift_without_ts <- plt_level_without_ts +
  plt_drift_without_ts +
  patchwork::plot_layout(ncol=1)

plot(plt_level_drift_without_ts)
```



```
plt_level_with_ts <- autoplot(res_with,
                              component=c("level")
                              ) +
  labs(title="Model with the PDO index") +
```

```



theme_classic()

plt_drift_with_ts <- autoplot(res_with,
                             component=c("drift")
                             ) +
  labs(title="Model with the PDO index") +
  theme_classic()

plt_level_drift_with_ts <- plt_level_with_ts +
  plt_drift_with_ts +
  patchwork::plot_layout(ncol=1)

plot(plt_level_drift_with_ts)

```



```

# Smoothing estimate of drift component
mean_drift_year_without <- get_drift_ts(res_without) %>%
  mean()
print(mean_drift_year_without)

```

```
## [1] 0.03601619
```

```

mean_drift_year_with <- get_drift_ts(res_with) %>%
  mean()
print(mean_drift_year_with)

```

```
## [1] 0.01142969
```

上の図の灰色の領域は、95% 信頼区間を示しています。

外生変数なしモデルでは、長期トレンドおよびその変化率のプロットに波打ったようなパターンが読み取れますが、外生変数ありモデルでは長期トレンドおよびその変化率はより安定的なパターンとなっています。つまり、この波打ったようなパターンは外生変数の PDO がおよぼす影響であることが示唆されます。

観測期間を通した SST の年あたりの変化率の推定値は、外生変数なしモデルでは 0.0360、外生変数ありモデルでは 0.0114 となりました。

今回のケースでは、SST のトレンドを正確に推定するには PDO 指数を組み込んだモデルの方が好ましいと考えられます。したがって外生変数なしモデルではやや大きめに推定されていた SST の上昇率が、外生変数ありモデルの導入によって、抑制的に推定されたことになります。

ユーザーのオリジナルデータの使用について

簡単な例

my_ts はユーザーが用意した温度時系列データの ts オブジェクトです。直接 tempssm() に渡すことができます。

```
## example of ts object (not run)
## my_ts <- ts(rnorm(100), frequency = 12)
res <- tempssm(my_ts)
```

ユーザーのオリジナルデータの準備

CSV 形式

月別温度時系列の CSV ファイルを、以下の列をもつ形式で準備します。- Year - Month - Temp

例:

```
Year,Month,Temp
2010,8,13.6
2010,9,6.8
2010,10,NA
2010,11,-1.4
...
```

- 欠測した温度値には NA を使用し、対応する Year と Month の行は必ず保持してください。
- CSV ファイルはカンマ区切りで、UTF-8 エンコーディングとしてください。

CSV から時系列への変換

本パッケージに同梱するサンプル CSV ファイルは inst/extdata にあります。このサンプルデータセットには、北海道赤岳 (1,840 m) における月別気温観測値が含まれています。オリジナルデータは環境省のモニタリングサイト 1000 から入手可能です。(KOZ01.zip、<https://www.biodic.go.jp/moni1000/findings/data/index.html>)。

```
path <- system.file("extdata", "example_monthly_temp.csv", package = "tempssm")
akadake_temp <- tempssm::read_monthly_temp_ts(path)
head(akadake_temp)
```

```
##           Jan Feb Mar Apr May Jun Jul   Aug   Sep   Oct   Nov   Dec
## 2010                                13.6   6.8   0.2  -6.8 -12.5
## 2011 -18.8
```

read_monthly_temp_ts() 関数は、内部で base R の ts() 関数を用いて時系列オブジェクトを作成します。より細かな制御が必要な場合は、手動で ts オブジェクトを作成することができます。

参考文献

tempssm に実装されている統計モデリングの枠組みは、Baba et al. (2024) に記述された方法論に基づいており、付随する補足資料およびコードリポジトリが本パッケージ開発の初期ソースとなっています。

Baba, S., Ishii, H., and Yoshiyama, T. (2024). Estimating sea temperature trends using a linear Gaussian state-space model in Jogashima, Kanagawa, Japan. *Bulletin of the Japanese Society of Fisheries Oceanography*, 88(3), 190–199. (日本語、英語要旨あり。) https://doi.org/10.34423/jsfo.88.3_190

Baba, S. (2024). 線形ガウス状態空間モデルを用いた海水温トレンド推定のための補足コードおよびテストデータ。GitHub リポジトリ: <https://github.com/logics-of-blue/sea-temperature-trend-jogashima>

Helske, J. (2017). KFAS: R における指数型分布族状態空間モデル。 *Journal of Statistical Software*, 78(10), 1–39. <https://doi.org/10.18637/jss.v078.i10>

付録: ユーティリティ関数

データ準備と探索的解析を支援するために、以下のユーティリティ関数が提供されています。

1. read_monthly_temp_ts()

read_monthly_temp_ts() 関数は、CSV ファイルに保存された月別温度データを R の ts オブジェクトへ変換します。単純で一貫したデータ形式を課すことで、外部で準備された時系列データを tempssm に取り込みやすくすることを目的としています。

例

月別温度データでは、ヘッダー行をもつ CSV ファイルを準備します。デフォルトでは、列名は Year、Month、Temp である必要があります。ここで Temp は観測された温度値を表します。

```
Year,Month,Temp
2001,1,10.4
2001,2,8.2
2001,3,NA
2001,4,13.6
2001,5,16.1
...
```

- 欠測した温度値には NA を使用し、対応する Year と Month の行は必ず保持してください。* CSV ファイルはカンマ区切りで、UTF-8 エンコーディングとしてください。

次の例では、パッケージに含まれるサンプル CSV ファイルを使用します。

```
tmp_csv <- tempfile(fileext = ".csv")
writeLines(
  c("Year,Month,Temp",
    "2001,1,10.4",
    "2001,2,8.2",
    "2001,3,NA",
    "2001,4,13.6",
    "2001,5,16.1"),
  tmp_csv
)

# Read the CSV file and convert to a monthly ts object
temp_ts <- read_monthly_temp_ts(tmp_csv)
```

2. convert_monthly_df_to_ts()

`convert_monthly_df_to_ts()` 関数は、月別温度データを含むデータフレームを R の `ts` オブジェクトへ変換します。この関数は、温度データをまずデータフレームとして読み込みまたは準備し、その後、時系列解析で使用するワークフローを支援するために設計されています。

入力データフレームには、少なくとも日付列 (`Date`) と温度列 (`Temp`) の 2 列が含まれていることが想定されています。なお日付列 (`Date`) について、月別の温度の集計値と対応させるために、日は任意の日数 (たとえば 1 日) を与えてください。

例

```
# Create a data frame of monthly temperature data
df <- data.frame(
  Date = as.Date(c(
    "2001-01-01",
    "2001-02-01",
    "2001-03-01",
    "2001-04-01",
    "2001-05-01"
  )),
  Temp = c(10.4, 8.2, NA, 13.6, 16.1)
)

# Convert to a monthly ts object
temp_ts <- convert_monthly_df_to_ts(df)
head(temp_ts)
```

```
##           Jan  Feb  Mar  Apr  May
## 2001 10.4   8.2   NA 13.6 16.1
```

3. get_jma_sst_ts()

`get_jma_sst_ts()` 関数は、気象庁 (JMA) が提供する日本沿岸域の日平均海面水温 (SST) データをダウンロードします。日別値を月平均へ集計し、得られた時系列を `ts` クラスのオブジェクトとして返します。

例

次の例では、茨城県南部沿岸域の SST データをダウンロードする方法を示します。

引数 `sea_area_id` は、JMA によって定義された海域の数値 ID を指定します。例えば、138 は茨城県南部沖の沿岸域に対応します。利用可能な海域 ID と対応する地域の一覧は、JMA により以下で提供されています。

https://www.data.jma.go.jp/kaiyou/data/db/kaikyo/series/engan/eg_areano.html

```
sst_138_ts <- get_jma_sst_ts(sea_area_id = 138)
head(sst_138_ts)
```

```
##           Jan           Feb           Mar           Apr           May           Jun
## 1982 15.04419 14.22500 13.63903 15.31933 17.52258 19.52300
```

4. compute_temp_anomaly()


`compute_temp_anomaly()` 関数は、R の `ts` オブジェクトとして与えられた時系列から偏差を計算します。偏差は、各観測値から対応する周期単位 (たとえば月) の長期平均を差し引くことで計算され、周期の影響を取り除いた年変動パターンの確認などに用いられます。

偏差を計算するための基準期間は、関数引数で指定できます。デフォルトでは、利用可能な時系列全体を用いて平年値が計算されます（`?compute_temp_anomaly` を参照）。

この変換は、典型的な季節条件からのずれに注目する探索的解析やモデリング用途で有用です。

例

```
# Generate temperature anomalies
data(niigata_sst)
niigata_sst_anomaly <- compute_temp_anomaly(niigata_sst)
plt_niigata_sst_anomaly <- forecast::autoplot(niigata_sst_anomaly) +
  labs(y = expression(Temp.~(degree*C)),
       x = "Time (year)")
plot(plt_niigata_sst_anomaly)
```



5. `compute_monthly_climatology()`

`compute_monthly_climatology()` 関数は、`ts` オブジェクトから、各季節値を年をまたいで平均することにより、気候学的な平均季節周期を計算します。主として、温度時系列における季節構造の探索的解析と可視化を目的としています。

例

```
data(niigata_sst)
monthly_seasonal_cycle_niigata_sst <- compute_monthly_climatology(niigata_sst)
summary(monthly_seasonal_cycle_niigata_sst)
```

```
##      Month      Temperature
## Min.   : 1.00   Min.   : 9.365
```

```
## 1st Qu.: 3.75    1st Qu.:11.169
## Median : 6.50    Median :16.318
## Mean   : 6.50    Mean   :17.036
## 3rd Qu.: 9.25    3rd Qu.:22.294
## Max.   :12.00    Max.   :26.873
```

```
plt_monthly_seasonal_cycle_niigata_sst <- ggplot(
  data = monthly_seasonal_cycle_niigata_sst,
  aes(x = Month, y = Temperature)
) +
  geom_point(size = 2) +
  geom_line(linetype = "dashed") +
  labs(
    title = "Monthly seasonal cycle of temperature",
    x = "Month",
    y = expression(Temp.~(degree*C))
  ) +
  scale_x_continuous(
    breaks = 1:12,
    labels = sprintf("%02d", 1:12)
  ) +
  theme_classic()
```

```
plot(plt_monthly_seasonal_cycle_niigata_sst)
```

